

Visualización y analítica de datos masivos

Práctica Informática - Propuesta Inicial v3

ALUMNO: RAQUEL ABREU HERNANDO

Como parte de la entrega final de la práctica informática, se entrega esta versión 3 del documento de la Propuesta Inicial de la Práctica, con las siguientes modificaciones respecto a la versión 2 del documento:

- **Objetivos:** Se reformulan los objetivos adecuándose dentro del proceso iterativo del análisis realizado en la práctica.
- **Fuentes de datos:** Se adecúan las fuentes de datos de forma apropiada a los objetivos reformulados en el análisis de la práctica.

Temática Objetivo de la visualización: Análisis del impacto del ruido en la vida de las personas.

1. Introducción

El objetivo del trabajo es la creación de una visualización utilizando la librería para visualización de Python Altair.

La visualización seguirá los principios de diseño de vistas y se elaborará sobre las fuentes de datos abiertas propuestas por el equipo docente que se enriquecerán con otras fuentes de datos abiertas adicionales.

2. Objetivo de la visualización redefinidos

El ruido ambiental constituye un factor de exposición urbana que no siempre es perceptible de forma explícita por la ciudadanía, pero que presenta efectos acumulativos sobre la calidad de vida. La visualización desarrollada tiene como objetivo **caracterizar y contextualizar la exposición al ruido**, así como **explorar su relación descriptiva con indicadores de salud, bienestar y prosperidad**, utilizando datos agregados y representaciones visuales interactivas.

El enfoque combina **escala local (ciudad de Madrid)** y **escala nacional (España)**, con el fin de ofrecer una visión contextual del fenómeno y facilitar su interpretación desde una perspectiva informada, apoyando la toma de decisiones basadas en datos, sin establecer inferencias causales.

Objetivo Global (OG) de la visualización: **Caracterizar de forma visual y comparativa el impacto potencial del ruido ambiental**, mediante la representación de niveles de exposición, población potencialmente afectada y su asociación descriptiva con

indicadores de salud, bienestar y prosperidad, integrando análisis a escala local (Madrid) y nacional (España).

La visualización global se centra en:

- Describir patrones generales de exposición al ruido.
- Contextualizar dichos patrones mediante indicadores agregados de bienestar y desarrollo.
- Facilitar una lectura comparativa entre territorios y dimensiones, sin pretender cuantificar efectos causales directos.

Objetivos Secundarios (OS) asociados al Objetivo Global (OG):

OS01 – Exposición acústica y contexto urbano en Madrid. Caracterizar la exposición al ruido ambiental en la ciudad de Madrid y su evolución temporal, mediante indicadores agregados por áreas urbanas, y contextualizarla en relación con el uso del espacio urbano y la experiencia ciudadana.

Este objetivo se materializa a través de visualizaciones que:

- Representan la distribución espacial y temporal de los niveles de ruido.
- Permiten comparar zonas con diferente intensidad acústica.
- Ofrecen una lectura descriptiva del entorno urbano sin incorporar métricas directas de percepción subjetiva.

OS02 – Ruido, salud y bienestar (escala local y nacional). Explorar de manera descriptiva la relación entre la exposición al ruido ambiental y distintos indicadores agregados de salud y bienestar, tanto a nivel local como nacional.

Las visualizaciones asociadas a este objetivo:

- Integran datos de exposición acústica con indicadores de salud y bienestar disponibles.
- Permiten identificar patrones y diferencias entre territorios.
- Se limitan a un análisis exploratorio y correlacional visual, condicionado por la agregación y disponibilidad de los datos.

OS03 – Ruido, prosperidad y desarrollo. Explorar asociaciones descriptivas entre la exposición al ruido ambiental y variables de prosperidad económica, como el nivel de ingresos, utilizando datos agregados y representaciones comparativas.

Este objetivo se aborda mediante visualizaciones que:

- Relacionan niveles de exposición acústica con indicadores económicos.
- Facilitan la comparación entre territorios y rangos de valores.
- No establecen relaciones de causalidad, sino que aportan contexto socioeconómico al fenómeno del ruido.

2.1. Justificación académica de la redefinición de los objetivos

La redefinición de los objetivos respecto a la formulación inicial responde a un **ajuste metodológico necesario**, derivado tanto de la **disponibilidad real de los datos** como del **alcance efectivo de las visualizaciones finales desarrolladas**.

En la propuesta inicial, los objetivos planteaban una formulación más ambiciosa en términos de **cuantificación de impactos directos** sobre salud, bienestar y productividad. No obstante, durante el desarrollo de la práctica se han identificado limitaciones relevantes:

- Los datos disponibles presentan **niveles de agregación geográfica y temporal que impiden establecer relaciones causales robustas.**
- La **heterogeneidad entre fuentes limita la comparabilidad directa** de algunos indicadores.
- El **enfoque principal del proyecto es la visualización y el análisis exploratorio**, no la modelización estadística inferencial.

Por este motivo, los objetivos se han reformulado para:

- Ajustarse al **alcance descriptivo y comparativo** de las visualizaciones producidas. Se adecúan para que sean factibles y adecuados a la carga de trabajo de la asignatura.
- Mantener coherencia entre **objetivos, datos y gráficos finales.**
- Evitar interpretaciones no válidas, reforzando la **validez académica y metodológica del trabajo.**

Esta redefinición de los objetivos no reduce el valor del proyecto, sino que lo sitúa en un marco alineado con las **buenas prácticas en visualización de datos**, donde la claridad, la honestidad analítica y la coherencia entre intención y resultado son prioritarias.

3. Fuentes de datos

Para el análisis del **Objetivo Global (OG)** se han seleccionado las siguientes fuentes de datos que permiten medir la exposición a ruido en distintos niveles, comparar indicadores globales de bienestar, desarrollo y prosperidad, analizar tendencias históricas y estándares regulatorios.

- [1] **Madrid – Contaminación acústica (SIVCA)** - datos diarios (LAeq, L10/L50/L90/L99). Fuente oficial del Ayuntamiento de Madrid con mediciones instrumentales. Incluye indicadores acústicos nominativos para caracterizar la exposición diaria.
<https://datos.madrid.es/dataset/215885-0-contaminacion-ruido>
- [2] **Madrid – Contaminación acústica, históricos mensuales (1998–).** Aporta continuidad temporal de evolución para detectar tendencias y cambios de comportamiento.
<https://datos.madrid.es/dataset/211356-0-contaminacion-acustica>
- [3] **EU - Noise Limit Details ES.** Define los límites normativos aplicables en España en franjas horarias y entornos. Permite contextualizar si los registros superan los límites legales.
<https://data.europa.eu/data/datasets/13c97329-c7dd-4bc3-9b85-1413b55434b4?locale=en>
- [4] **World Bank –Social, economic, environment and institutions indicators in Spain.** Incluye indicadores socioeconómicos, medioambientales de España. Adecuado para relacionar la exposición al ruido con índices de desarrollo a nivel nacional.
<https://data.worldbank.org/country/spain>. Derivado del análisis y procesado de datos de la Entrega Intermedia el dataset [4] no se utiliza en la visualización de la práctica

Para el análisis del **Objetivo Secundario 01 exposición y experiencia ciudadana en Madrid**, se han seleccionado fuentes de datos que permiten un análisis del ruido existente, dónde se genera y cómo impacta en la vida del ciudadano en Madrid.

- [5] **Estaciones de medida (georreferenciadas).** Los datos de ubicación de las estaciones de medida permiten zonificar el nivel de ruido en Madrid.
<https://datos.madrid.es/dataset/211346-0-estaciones-acusticas>
- [6] **Censo de locales y terrazas (uso del espacio público).** El censo de locales permite identificar fuentes potenciales de ruido. <https://datos.madrid.es/dataset/200085-0-censo-locales>
- Para el análisis del OS-01 se utilizarán los **datasets [1] SIVCA y [2]** del OG con las fuentes oficiales del Ayuntamiento de Madrid que incluyen las medidas del ruido en Madrid. Además del dataset **[3] con la información de los límites normativos**. Adicionalmente se utilizará el dataset **[7] con información de los indicadores multidimensionales de bienestar y calidad de vida**, que se introducirá en el dataset del Objetivo Secundario 02.

Para el análisis del **Objetivo Secundario 02 ruido, salud y bienestar (local y nacional)** se han seleccionado estas fuentes de datos que permiten vincular la exposición al ruido con indicadores oficiales de salud y bienestar.

- [7] **INE – Indicadores de Calidad de Vida (ICV).** Ofrece indicadores multidimensionales de bienestar (salud, entorno, calidad ambiental).
<https://datos.gob.es/es/catalogo/ea0010587-indicadores-de-calidad-de-vida>
- [8] **INE – Salud mental (encuesta de salud).** Aporta métricas de salud mental a nivel nacional. <https://datos.gob.es/es/catalogo/ea0010587-salud-mental-segun-sexo-y-grupo-de-edad-poblacion-de-15-y-mas-anos-identificador-api-48130>. Derivado del análisis y procesamiento de datos de la Entrega Intermedia el dataset [8] no se utiliza en la visualización de la práctica.
- **Se utilizará el dataset [1] SIVCA y [2] del OG** para cuantificar el nivel de ruido local, en Madrid. Permite la correlación de la exposición real con indicadores de salud. Además del dataset **[3] con la información de los límites normativos**.

Para el análisis de los **Objetivo Secundario 03 prosperidad y desarrollo**, se han seleccionado las siguientes fuentes de datos que permiten explorar patrones entre ruido e ingresos, manteniendo un enfoque descriptivo y no causal.

- [9] **INE – Atlas de Distribución de Renta de los Hogares (ADRH).** Permite analizar el nivel de renta por zona.
https://www.ine.es/dyngs/INEbase/operacion.htm?c=Estadistica_C&cid=1254736177088&menu=ultiDatos&idp=1254735976608
- Para el análisis del OS-03 se utilizará el **datasets [2]** del OG con los datos oficiales del Ayuntamiento de Madrid que incluyen las medidas del ruido en Madrid. Además del dataset **[3] con la información de los límites normativos**.

3.1. Evolución y justificación de las fuentes de datos utilizadas

Durante el desarrollo del proyecto, las fuentes de datos inicialmente seleccionadas fueron objeto de un proceso de revisión y ajuste iterativo en espiral progresivo con el fin de garantizar la coherencia entre los objetivos de la visualización, la calidad de los datos disponibles y el alcance real de los análisis representados.

En la fase inicial se contempló un conjunto amplio de fuentes oficiales, tanto locales como nacionales e internacionales, orientadas a cuantificar la exposición al ruido y relacionarla con indicadores de salud, bienestar y prosperidad.

Sin embargo, tras el análisis exploratorio y el posterior procesamiento de los datos, **algunas fuentes fueron descartadas** al comprobarse que no aportaban información cuantitativa relevante o presentaban un nivel de agregación incompatible con los objetivos visuales del proyecto. En particular, los conjuntos de datos relativos a metadatos de indicadores del Banco Mundial [4] y a salud mental [8] fueron excluidos por carecer de valores analizables o por no mostrar una relación interpretativamente significativa con las variables de exposición al ruido.

Paralelamente, el proceso de limpieza, normalización e integración dio lugar a un conjunto consolidado de datasets procesados, alojados en el repositorio público de Kaggle, cuya **versión final (v5) incorpora**, además de las fuentes originales depuradas, **dos datasets adicionales generados de forma sintética**. Estos conjuntos sintéticos se han creado específicamente para facilitar determinadas visualizaciones, mediante la agregación y reestructuración de información ya existente, sin introducir datos externos ni alterar el contenido semántico de las fuentes originales.

En conjunto, **la evolución de las fuentes de datos refleja una adaptación metodológica** orientada a priorizar la trazabilidad, la reproducibilidad y la adecuación de los datos a un enfoque de visualización descriptiva y comparativa, reforzando así la validez académica y la coherencia global del proyecto.

4. Planificación del caso práctico

La planificación del caso práctico se estructura siguiendo un **proceso incremental basado en la metodología en espiral de análisis de datos**, tal como se establece en los contenidos de la asignatura: preprocesado, análisis (procesado), evaluación y refinado.

Una vez definidos el Objetivo Global (OG) y los Objetivos Secundarios (OS01, OS02 y OS03), se desarrolla un análisis iterativo en ciclos de análisis con las siguientes fases:

- **Fase de Preprocesado:** se procede a la adquisición, depuración y preparación inicial de los datos incluyendo:
 - Selección y consolidación de fuentes según cada objetivo de análisis.
 - Identificación de condiciones de contexto, espaciales, temporales, normativas y de calidad del dato.
 - Transformación inicial en un Jupyter Notebook aplicando:
 - Limpieza y gestión de valores vacíos.
 - Normalización y estandarización de variables.
 - Generación de nuevas variables derivadas.
 - Integración de datasets.
- **Fase de Procesado y análisis.** Estudio planificado y procesado formal de los datos para obtener patrones, relaciones y distribuciones relevantes.
 - **Ordenación estructurada de los datos:** temporal, espacial y por magnitudes.

- **Agrupación o clustering** para identificar patrones de comportamiento o zonas homogéneas.
- **Escalado y normalización** de los datos.
- **Combinación de información** entre fuentes heterogéneas (niveles de ruido, socioeconómica, salud).
- **Análisis de correlación y ocurrencia**, distinguiendo entre correlación u causalidad.

El análisis se apoyará en visualizaciones con Python Altair que se seleccionarán según las necesidades del estudio:

- Series temporales y áreas para visualizar la evolución histórica del ruido.
- Dispersión para representar datos de exposición y renta.
- Burbujas para representar datos de exposición y población.
- Mapas de calor de correlación para identificar correlaciones.
- Mapas geoespaciales para representación por zonas de datos de exposición, renta y bienestar.

El objetivo es obtener resultados alineados con las hipótesis que se plantean para cada objetivo (OG y OS).

- **Fase de evaluación de resultados.** Se revisan los resultados obtenidos para comprobar su coherencia con las hipótesis planteadas y con el comportamiento esperado según literatura y normativas. En esta fase:
 - Se validarán patrones.
 - Se identificarán datos atípicos, inconsistencias o nuevas relaciones.
 - Se generarán nuevas hipótesis para el siguiente ciclo del análisis.
- **Fase de propuesta de mejoras y refinado.** En esta fase se analizarán críticamente:
 - El conjunto de datos utilizado evaluando completitud y sesgos.
 - El proceso de análisis revisando las representaciones visuales, selección de variables y técnica de análisis aplicadas.

El objetivo es introducir mejoras iterativas, en calidad de los datos y en las visualizaciones, dando lugar a un nuevo ciclo de análisis en línea con la metodología en espiral.

En el proceso de análisis de datos se elaborará un **registro metodológico** con las referencias a las fuentes de datos utilizadas, transformaciones, decisiones analíticas, suposiciones, limitaciones y decisiones consideradas en el proceso de análisis. Este registro garantiza trazabilidad, reproducibilidad y ética del proceso.

Generación del informe final y storytelling. Una vez los resultados concuerdan y tienen la calidad suficiente. Se elabora:

- El **informe final** con las conclusiones y visualizaciones interpretadas.
- El **storytelling** estructurado, con las piezas visuales seleccionadas, siguiendo principios de narrativa visual y claridad.
- El **vídeo explicativo** que sintetiza el caso práctico orientado a la audiencia.

5. Planificación temporal del caso práctico

Entrega propuesta inicial: límite 13/03/2026

- Preparación entrega inicial: 2/02/2026-13/03/2026

Entrega intermedia: límite 13/04/2026

- Fase de Preprocesado: 13/03/2026-1/04/2026
- Fase de Procesado: 1/04-13/04/2026
- Preparación de entrega intermedia: 23/03-13/04/2026

Entrega final: límite 15/05/2026

- Fase de análisis: 13/04-1/05/2026 (en ciclos iterativos)
- Fase de evaluación de resultados: 20/04-5/05/2026 (en ciclos iterativos)
- Fase de propuesta de mejoras y refinado: 20/04-5/05/2026 (en ciclos iterativos)
- Fase de elaboración de Storytelling: 20/04-10/05/2026
- Fase de elaboración informe final/memoria: 20/04-14/05/2026

Fase Registro metodológico: 13/03-14/05/2026

Entrega de vídeo: límite 20/5/2026

- Fase elaboración vídeo: 5/05-20/5/2026




Figura 1: Diagrama de Gantt – Planificación temporal del caso práctico